PANDUAN LATIHAN UTS DATA ANALYSIS LAB

PYTHON
PANDAS • NUMPY • EDA

Ringkasan sintaks inti, pola pengerjaan, dan contoh kode yang bisa disesuaikan dengan dataset ujian.

Acuan materi

Prioritas	Sumber	Cara digunakan
1	Rubrik dosen UTS Lab	Menentukan kompetensi yang dilatih: pemeriksaan dataset, perhitungan variabel, visualisasi, Z-score, dan kategorisasi.
2	Jawaban UTS Lab 2025	Contoh pola file Passengers.csv, Stations.xlsx, Routes.xlsx, merge, Fare_IDR, tiga grafik, dan kategori penumpang.
3	Materi LEC Datnal	Tambahan cleaning, imputasi, IQR, groupby, value_counts, np.where, dan struktur data Python.

Catatan: Contoh dataset dan angka hasil hanya untuk latihan. Rubrik dosen tetap acuan utama. Gunakan nama kolom, batas kategori, rumus, dan jenis grafik yang secara nyata diminta saat ujian.

File pendamping: Panduan_Latihan_UTS_Data_Analysis_Lab.ipynb. Notebook tersebut berisi contoh kode yang bisa dijalankan, dataset latihan, dan output grafik.

1. Alur kerja dan pola wajib

Gunakan alur ini sebagai kerangka. Jangan mulai dari visualisasi sebelum memahami struktur dan kualitas datanya.

Tahap	Tujuan	Sintaks inti
Baca file	Memuat data ke DataFrame	pd.read_csv(...) pd.read_excel(...)
Pahami data	Dimensi, tipe, missing, duplikat	.shape, .info(), .dtypes, .isna().sum(), .duplicated().sum()
Ringkas data	Statistik dan contoh baris	.describe(), .head(), .tail()
Gabungkan	Menambah informasi melalui key	df1.merge(df2, on="key", how="left")
Buat kolom	Menghitung variabel baru / kategori	df["baru"] = ... np.where(...) / np.select(...) / pd.cut(...)
EDA	Visualisasi dan pola	sns.boxplot(...), plt.hist(...), plt.bar(...)
Outlier	Z-score dan persentase	stats.zscore(...); jumlah / total * 100

Template pemeriksaan cepat untuk satu DataFrame

```
print(df.shape)
print(df.dtypes)
print(df.isnull().sum())
print("Duplikat:", df.duplicated().sum())
print(df.describe())
print(df.head(5))
print(df.tail(5))
```

Cara membaca `.shape`: hasilnya `(baris, kolom)`. `describe()` secara default merangkum kolom numerik. Untuk merangkum kolom kategorikal juga, gunakan `df.describe(include="all")`.

2. Q1 — Dataset Understanding

Di referensi tahun 2025, tiga file dibaca sebagai berikut. Ganti nama file dengan file yang benar-benar diberikan saat ujian.

```
import pandas as pd

dfRoutes = pd.read_excel('Routes.xlsx')
dfStations = pd.read_excel('Stations.xlsx')
dfPassengers = pd.read_csv('Passengers.csv')

print('Routes:', dfRoutes.shape)
print('Stations:', dfStations.shape)
print('Passengers:', dfPassengers.shape)
```

Periksa masalah kualitas data

```
print(df.dtypes)
print(df.isnull().sum())
print('Duplikat:', df.duplicated().sum())
print(df[df.duplicated(keep=False)])
```

Konversi tipe numerik

```
df['Fare_USD'] = pd.to_numeric(df['Fare_USD'], errors='coerce')
print(df['Fare_USD'].dtype)
print('Nilai gagal konversi:', df['Fare_USD'].isna().sum())
```

Merge berdasarkan `Station_ID`

```
mergedData = (
    dfPassengers
    .merge(dfStations, on='Station_ID', how='left')
    .merge(dfRoutes, on='Station_ID', how='left')
)
print('Setelah merge:', mergedData.shape)
print(mergedData.head())
```

Konversi USD ke IDR dan statistik

```
mergedData['Fare_IDR'] = mergedData['Fare_USD'] * 16000
print(mergedData.describe())
print(mergedData.dtypes)
print(mergedData.head(5))
print(mergedData.tail(5))
```

Pemeriksaan setelah merge

Pastikan key tersedia di kedua dataset. Jika jumlah baris setelah merge bertambah, periksa key duplikat pada tabel metadata. `how="left"` mempertahankan semua baris dari DataFrame di sebelah kiri, tetapi kolom hasil tetap bisa berisi missing value jika key tidak cocok.

3. Q2 — Data Formatting dan kolom baru

Rubrik menekankan pembuatan variabel baru melalui perhitungan. Ganti variabel dan operasi aritmetika mengikuti rumus yang tertulis di soal.

Pola umum

```
df['New_Column'] = df['Variable_1'] * df['Variable_2']
```

Contoh untuk dataset transportasi: estimasi pendapatan = jumlah penumpang × tarif dalam Rupiah.

```
mergedData['Estimated_Revenue_IDR'] = (
    mergedData['Passengers'] * mergedData['Fare_IDR']
)
```

Kategori tarif dari contoh UTS sebelumnya

Kondisi Fare_IDR	Label
Kurang dari 10.000	Low
10.000 sampai 20.000, inklusif	Medium
Lebih dari 20.000	High

```
conditions = [
    mergedData['Fare_IDR'] < 10000,
    mergedData['Fare_IDR'].between(10000, 20000, inclusive='both')
]
mergedData['Fare_Category'] = np.select(conditions, ['Low', 'Medium'], default='High')
print(mergedData[['Fare_IDR', 'Fare_Category']].head(10))
```

Mengapa `np.select`? Batas interval menjadi eksplisit: 10.000 dan 20.000 masuk kategori Medium. Jika memakai `pd.cut`, perhatikan argumen `right` dan tepi bin karena nilai tepat di batas bisa berpindah kategori.

Variasi operasi yang mungkin diminta

Operasi	Contoh	Catatan
Perkalian	df["Total"] = df["Quantity"] * df["Unit_Price"]	Umum untuk nilai transaksi.
Konversi unit	df["Fare_IDR"] = df["Fare_USD"] * 16000	Pakai faktor konversi yang diberikan soal.
Kondisi	np.where(df["X"] >= batas, "High", "Low")	Cocok untuk dua kategori.

4. Q2 — Tiga pola visualisasi

Pada referensi UTS 2025, grafik yang diminta adalah boxplot Passengers per Zone, histogram Fare_IDR dengan 50 bins, dan bar chart rata-rata Passengers per Transport_Type. Gunakan grafik yang benar-benar diminta dosen jika berbeda.

1) Boxplot: bandingkan distribusi numerik antar kelompok

```
plt.figure(figsize=(7, 5))
sns.boxplot(data=mergedData, x='Zone', y='Passengers')
plt.title('Boxplot Passengers per Zone')
plt.xlabel('Zone')
plt.ylabel('Passengers')
plt.tight_layout()
plt.show()
```

2) Histogram: distribusi satu kolom numerik

```
plt.figure(figsize=(7, 5))
plt.hist(mergedData['Fare_IDR'].dropna(), bins=50, edgecolor='black')
plt.title('Histogram Fare_IDR (50 bins)')
plt.xlabel('Fare_IDR')
plt.ylabel('Frekuensi')
plt.tight_layout()
plt.show()
```

3) Bar chart: rata-rata penumpang per transportasi

```
avg = mergedData.groupby('Transport_Type')['Passengers'].mean()
avg = avg.sort_values(ascending=False)
plt.figure(figsize=(7, 5))
plt.bar(avg.index.astype(str), avg.values, edgecolor='black')
plt.title('Average Passengers per Transport Type')
plt.xlabel('Transport_Type')
plt.ylabel('Average Passengers')
plt.xticks(rotation=25, ha='right')
plt.tight_layout()
plt.show()
```

Kalimat interpretasi yang aman

"Grafik menunjukkan bahwa [kelompok A] memiliki [median/rata-rata/sebaran] lebih [tinggi/rendah] daripada [kelompok B]. Terlihat pula [pola/outlier]. Hal ini menunjukkan [interpretasi langsung dari grafik], tetapi grafik saja belum membuktikan penyebabnya."

5. Q3 — Z-score, outlier, persentase

Z-score mengukur seberapa jauh nilai dari rata-rata dalam satuan standar deviasi. Pada contoh referensi, ambang latihan adalah ±3; gunakan batas yang disebutkan dalam instruksi aktual.

```
from scipy import stats

z_scores = pd.Series(
    stats.zscore(mergedData['Passengers'], nan_policy='omit'),
    index=mergedData.index
)
outlier_mask = z_scores.abs() > 3
outliers = mergedData.loc[outlier_mask].copy()

rows_total = len(mergedData)
outlier_count = int(outlier_mask.sum())
outlier_percentage = outlier_count / rows_total * 100 if rows_total else 0

print('Total baris:', rows_total)
print('Jumlah outlier:', outlier_count)
print('Persentase outlier: {:.2f}%'.format(outlier_percentage))
print('Shape sebelum:', mergedData.shape)
print('Shape setelah:', mergedData.loc[~outlier_mask].shape)
print(outliers[['Passengers']])
```

Contoh interpretasi

"Dari total N baris, ditemukan K outlier (P%). Ini berarti P% data memenuhi kriteria outlier berdasarkan ambang Z-score yang digunakan. Nilai tersebut perlu ditinjau lebih lanjut; tidak otomatis harus dihapus karena bisa merupakan kesalahan maupun kejadian nyata."

Pengecekan penting

Hal	Ingat
Ambang	Contoh: `abs(Z-score) > 3`; ikuti nilai ambang dari soal jika berbeda.
Persentase	`jumlah_outlier / total_baris * 100`.
Missing values	Jika kolom mengandung NaN, perhatikan `nan_policy="omit"` dan denominator yang diminta soal.
Data asli	Simpan hasil filter di DataFrame baru; jangan menghapus nilai dari data asli kecuali diminta.
Nama variabel	Python membedakan `outlierCount` dan `outlier_count`. Gunakan satu nama secara konsisten.

Alternatif metode pada materi LEC: IQR

```
q1 = df['X'].quantile(0.25)
q3 = df['X'].quantile(0.75)
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
outliers = df[(df['X'] < lower) | (df['X'] > upper)]
```

IQR disertakan sebagai referensi tambahan. Untuk rubrik Lab yang secara khusus menyebut Z-score, prioritaskan Z-score.

6. Q4 — Kategori dan preprocessing

Contoh kategori di referensi UTS 2025: Passengers < 300 = Low, 300 sampai 700 inklusif = Medium, dan > 700 = High.

```
conditions = [
    mergedData['Passengers'] < 300,
    mergedData['Passengers'].between(300, 700, inclusive='both')
]
mergedData['Passenger_Level'] = np.select(conditions, ['Low', 'Medium'], default='High')
print(mergedData[['Passengers', 'Passenger_Level']].head(10))
```

Jika memakai `pd.cut`

```
# Untuk kolom Passengers yang berupa bilangan bulat:
mergedData['Passenger_Level'] = pd.cut(
    mergedData['Passengers'],
    bins=[-np.inf, 300, 701, np.inf],
    labels=['Low', 'Medium', 'High'],
    right=False
)
```

Batas `701` dipakai pada contoh bilangan bulat agar 300–700 masuk Medium dan nilai 701 ke atas menjadi High. Untuk data kontinu atau batas yang berbeda, sesuaikan bin dengan aturan soal.

Template menangani missing values dan duplikat

```
# Hapus baris duplikat persis
df = df.drop_duplicates().copy()

# Numerik -> median (contoh)
df['Age'] = df['Age'].fillna(df['Age'].median())

# Kategorikal -> modus (contoh)
df['City'] = df['City'].fillna(df['City'].mode()[0])

# Konversi string ke tanggal
df['Order_Date'] = pd.to_datetime(df['Order_Date'], errors='coerce')
```

Pilih metode berdasarkan karakter kolom

Situasi	Cara umum	Alasan
Numerik memiliki missing	Median atau mean sesuai distribusi/instruksi	Mean sensitif terhadap outlier; median lebih tahan nilai ekstrem.
Kategorikal memiliki missing	Modus	Rata-rata tidak bermakna untuk nama kategori.
Baris duplikat	drop_duplicates()	Menghindari baris terhitung dua kali.
Tanggal sebagai teks	pd.to_datetime()	Memungkinkan pengurutan dan hitung selisih tanggal.

7. Tambahan dari materi LEC

Gunakan operasi berikut jika sesuai dengan pertanyaan. Jangan menambah proses yang tidak diminta hanya karena kodenya tersedia.

Ringkasan agregasi dengan `groupby`

```
summary = df.groupby('Category')['Total_Price'].agg(['count', 'sum', 'mean'])
print(summary)
```

Menghitung frekuensi kategori

```
print(df['Payment'].value_counts(dropna=False))
```

Membuat label berbasis syarat

```
df['Order_Size'] = np.where(df['Total_Price'] >= 500000, 'Large', 'Small')
```

Persentil

```
p75 = np.percentile(df['Total_Price'].dropna(), 75)
print('P75:', p75)
```

Menghitung nilai transaksi

```
df['Total_Price'] = df['Quantity'] * df['Unit_Price']
```

List, dictionary, dan set

Struktur	Contoh singkat	Kegunaan
List	categories = df["Category"].unique().tolist()	Daftar nilai kategori berurutan; dapat berisi duplikat jika dibuat manual.
Dictionary	mapping = {"Female": 0, "Male": 1}	Mapping key ke value.
Set	ids_a = set(df1["ID"])	Elemen unik dan operasi irisan/selisih.

Kapan memakai operasi ini?

`groupby().agg()` untuk ringkasan numerik per kategori; `value_counts()` untuk frekuensi; `np.where()` atau `np.select()` untuk kategori berbasis kondisi; `np.percentile()` untuk persentil; dan `.merge()` untuk menggabungkan tabel berdasarkan key.

8. Lembar kilat sebelum UTS

Pola yang sebaiknya bisa kamu tulis tanpa melihat catatan:

```
# Baca file
df = pd.read_csv('file.csv')
# df = pd.read_excel('file.xlsx')

# Pahami data
print(df.shape)
print(df.dtypes)
print(df.isna().sum())
print(df.duplicated().sum())
print(df.describe())
print(df.head(5)); print(df.tail(5))

# Merge
merged = df1.merge(df2, on='ID', how='left')

# Kolom baru dari perhitungan
df['New'] = df['A'] * df['B']

# Kategori dua kondisi
df['Level'] = np.where(df['X'] >= cutoff, 'High', 'Low')

# Z-score + persentase
z = stats.zscore(df['X'], nan_policy='omit')
mask = np.abs(z) > 3
outlier_pct = mask.sum() / len(df) * 100

# Visualisasi
sns.boxplot(data=df, x='Category', y='Value')
plt.hist(df['Value'].dropna(), bins=50)
df.groupby('Category')['Value'].mean().plot(kind='bar')
```

Kesalahan yang paling mudah dihindari

Kesalahan	Pencegahan
Nama kolom/file tidak sama	Periksa `df.columns` dan nama file persis seperti yang diberikan.
Key merge salah	Pastikan key ada dan memiliki arti yang sama di kedua tabel.
Batas kategori keliru	Tulis kondisi `<`, `<=`, `between`, dan tepi `pd.cut` sesuai soal.
Persentase salah	Gunakan jumlah outlier dibagi total baris sesuai permintaan lalu dikali 100.
Hanya menampilkan grafik tanpa label	Tambahkan judul, xlabel, ylabel, serta legend jika dibutuhkan.
Menghapus outlier tanpa diminta	Deteksi dulu; hapus hanya bila instruksi memerintahkannya.

Struktur kalimat interpretasi

"Pemeriksaan menunjukkan dataset berisi ... baris dan ... kolom. Setelah penggabungan berdasarkan ..., hasilnya memiliki ... baris. Analisis/visualisasi menunjukkan ... . Dengan kriteria ..., terdapat ... outlier atau ...% dari total data. Kolom kategori dibuat berdasarkan batas yang ditetapkan pada soal."

Sumber penyusunan: rubrik UTS Lab yang dikirim dalam bentuk foto; file jawaban UTS Lab 2025; dan PDF materi contoh jawaban + kode LEC Datnal. Dataset ilustrasi dalam notebook bukan dataset resmi dosen.